EXAMEN: Computergebruik

Prof. Dr. Peter Dawyndt 1^e Bachelor Informatica groep 1 woensdag 23-01-2008, 8:30h academiejaar 2007-2008 eerste zittijd

Opgave 1

Het bestand dna.txt bevat regels die telkens uit twee velden bestaan, gescheiden door een spatie. In het eerste veld staan woorden die geen hoofdletters bevatten, en in het tweede veld staan DNA sequenties van 100 basen. Een DNA sequentie wordt voorgesteld door een tekenreeks met lettertekens uit het alfabet $\{A, G, C, T\}$, waarbij elk letterteken een base genoemd wordt.

- 1. Bepaal reguliere expressies voor elk van de onderstaande verzamelingen, waarbij \mathcal{D} de verzameling van alle DNA sequenties voorstelt. Probeer deze reguliere expressies zo kort mogelijk te houden.
 - (a) $\alpha = \{d \in \mathcal{D} \mid \text{eerste en laatste drie basen van } d \text{ zijn dezelfde, maar volgorde is omgekeerd}\}$ voorbeeld: AGC...CGA
 - (b) $\beta = \{d \in \mathcal{D} \mid \text{geen enkel kwintet van basen in } d \text{ is hetzelfde}\}$
 - (c) $\gamma = \{d \in \mathcal{D} \mid \text{gedegenereerde sequentie BADMAN matcht juist één keer in } d\}$ uitleg: Een positie binnen een DNA sequentie die meerdere mogelijke alternatieve waarden kan hebben, wordt voorgesteld door een gedegenereerd basesymbool. Hieronder staat een lijst van alle gedegenereerde basesymboolen die internationaal werden vastgelegd.

base	betekenis	1	base	betekenis
W	A of T		В	G of T of C
S	G of C		D	G of A of T
M	A of C		H	A of C of T
K	G of T		V	G of C of A
R	G of A		N	A of G of C of T
Y	T of C			

Gebruik een commando uit de grep familie om enkel die regels van het bestand dna.txt te selecteren met een DNA sequentie die tot de opgegeven verzameling behoort. Vermeld in je antwoordbestand voor elke verzameling het gebruikte selectiecommando, en geef ook aan hoeveel regels je gevonden hebt.

- 2. Beschouw de verzamelingen α , β en γ zoals hierboven gedefinieerd. Gebruik nu deze verzamelingen om op de volgende manier een boodschap bestaande uit drie woorden te achterhalen:
 - (a) Het eerste woord staat op de unieke regel met de DNA sequentie uit verzameling $\alpha \cap \beta$.
 - (b) Het tweede woord staat op de unieke regel met de DNA sequentie uit verzameling $\alpha \cap \gamma$.
 - (c) Het derde woord staat op de unieke regel met de DNA sequentie uit verzameling $\beta \cap \gamma$.

Vermeld in je antwoordbestand de gevonden woorden, samen met de regelnummers in het bestand dna.txt waarop deze woorden gevonden werden. Geef voor elk woord ook het grep commando (of de commando-sequentie) die je gebruikt hebt om het woord te vinden.

Gegeven is een bestand aankomsttijden.txt, waarvan de regels de volgende vorm hebben:

<dag_aankomst> <uur_aankomst> <stad_oorsprong> <land_oorsprong> <maatschappij> <vlucht> <status>

Elke regel bevat informatie over een binnenkomend vliegtuig op de luchthaven van Zaventem, waarbij komma's gebruikt worden als veldscheidingsteken. Sommige velden worden ook nog ingesloten tussen dubbele aanhalingstekens. Verder komen er geen aanhalingstekens en komma's meer voor binnen de velden. Het bestand bevat bovendien ook nog commentaarregels die beginnen met een hekje (#). Gevraagd wordt om, gebruik makend van de teksteditor vi, een reeks substitutiecommando's te geven die achtereenvolgens de volgende opdrachten uitvoeren.

- 1. Wijzig het datumformaat van dd/mm/jjjj naar jj-mm-dd. De datum 21/01/2008 wordt dan bijvoorbeeld 08-01-21.
- 2. Verwijder het derde veld, en voeg datum en uur uit het eerste en het tweede veld samen, gescheiden door een spatie.
- 3. Gebruik drie commando's om elk veld in te sluiten tussen dubbele aanhalingstekens. Twee commando's om het begin en einde van een regel op te vangen, en één om de aanhalingstekens bij de veldscheidingen aan te passen. Maak daarna deze wijzigingen terug ongedaan (eventueel door het bestand opnieuw te openen).
- 4. Gebruik één enkel commando om elk veld in te sluiten tussen dubbele aanhalingstekens. Dit commando moet dus hetzelfde netto-effect hebben als de commando's uit het voorgaande puntje.
- 5. Reorganiseer het bestand zodat de records geordend zijn op land van oorsprong en daarna op vluchtmaatschappij. Zorg ervoor dat de regels na herorganisatie dezelfde vorm behouden. Het kan zijn dat je hierbij meer dan één commando nodig hebt, maar de optimale oplossing gebruikt slechts één enkel commando.
- 6. Indien er meerdere vluchtnummers zijn, dan worden die in het veld vlucht gescheiden door een puntkomma. Zorg ervoor dat in de kolom vlucht enkel het eerste vluchtnummer behouden wordt indien er meerdere vluchtnummers gegeven zijn. Voeg de andere vluchtnummers achteraan toe aan het veld status, maar voor het dubbele aanhalingsteken. De tweede regel met vluchtgegevens wordt dan bijvoorbeeld:

```
"08-01-21 13:00", "Frankrijk", "Brussels Airlines", "SN3618", "Geland 12:45; AY6668"
```

Probeer zo weinig mogelijk commando's te geven en zo weinig mogelijk tekens te gebruiken in je commando's. De commentaarregels in aankomsttijden.txt mogen door je substituties niet gewijzigd worden. Alle wijzigingen moeten na elkaar uitgevoerd worden. Vermeld de gebruikte substitutiecommando's op je antwoordbestand.

Opgave 3

Gegeven zijn de volgende tekstfragmenten:

1. **Definitie 1** Een lineaire k-stapsmethode voor y' = f(x,y) is van de vorm

$$\sum_{j=0}^{k} \alpha_j y_{n+j} = h \sum_{j=0}^{k} \beta_j f_{n+j},$$
 (1)

waarbij $\alpha_k = 1$ en $|\alpha_0| + |\beta_0| \neq 0$.

2. Een andere methode wordt gegeven door

$$y_{n+q} - y_{n+q-l} = h \sum_{i=0}^{q-u} \gamma_i \nabla^i f_{n+q-u},$$
 (2)

waarbij
$$\gamma_i = (-1)^i \int_{u-l}^u {t \choose i} dt$$
.

De methode (2) kan herschreven worden in de vorm (1) door de coëfficiënten te groeperen volgens de punten x_{n+j} :

$$y_{n+q} - y_{n+q-l} = h \sum_{i=0}^{q-u} \gamma_i \nabla^i f_{n+q-u}$$

$$= \dots$$

$$= h \sum_{m=0}^{q-u} \left((-1)^m \sum_{i=m}^{q-u} \gamma_i \begin{pmatrix} i \\ m \end{pmatrix} \right) f_{n+q-u-m}$$

$$= \dots$$

$$= h \sum_{j=0}^{q-u} \beta_j f_{n+j}$$

3. De tabel

		Tot	taal aantal
		luister aars:	beluisterde liedjes:
1	Radiohead	102151	1281855
2	The Beatles	80529	933796
3	Red Hot Chili Peppers	69498	528741
4	Muse	61513	596730
5	Coldplay	59033	420428
6	Metallica	57317	507478
7	The Killers	56047	431874
8	Linkin Park	55694	530503
9	Foo Fighters	54883	402888
10	Nirvana	53420	383323

geeft een overzicht van de tien meest populaire artiesten op Last.fm (http://www.last.fm).

Hint: Om overtollig typwerk te vermijden, kan je de gegevens uit de tabel kopiëren uit het bestand chart.txt, waar de velden worden gescheiden door tabs.

Gevraagd wordt om IATEX-code te genereren die precies hetzelfde resultaat oplevert als de tekstfragmenten binnen de bovenstaande kaders. Zorg ervoor dat formules en eigen omgevingen automatisch genummerd worden, en gebruik waar mogelijk verwijzingen naar deze nummeringen.

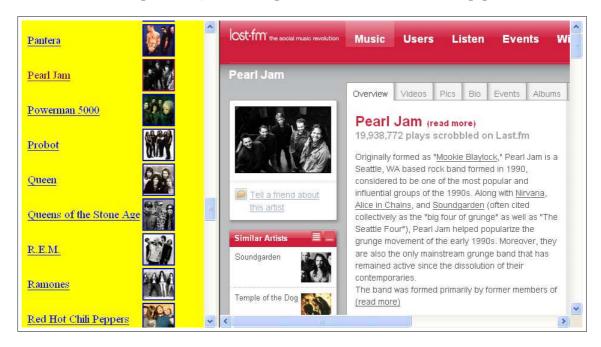
Opgave 4

Gevraagd wordt om een bash shell script verwante_groepen te schrijven, waarmee de gebruiker kan navigeren in een lijst van muziekgroepen die verwant zijn aan een opgegeven muziekgroep. Deze muziekgroep moet als parameter aan het shell script doorgegeven worden. De lijst van verwante groepen dient te worden opgemaakt in XHTML formaat. De weergave moet gebruik maken van twee

verticale frames, waarbij de lijst van groepen in het linkerframe wordt weergegeven. Zo moet het commando

> verwante_groepen metallica

een reeks van bestanden genereren, die als volgt in een browser worden weergegeven:



Bovendien moeten alle webpagina's die het script genereert voldoen aan de XHTML 1.0 standaard. Om een lijst van verwante muziekgroepen te genereren, maak je gebruik van de webservice

http://ws.audioscrobbler.com/1.0/artist/<groep>/similar.xml

Binnen deze template-URL vul je op de plaats van <groep> de naam van een artiest of muziekgroep in. Let erop dat de naam van de artiest of muziekgroep uit meerdere woorden kan bestaan. Voor het bovenstaande voorbeeld wordt dit

http://ws.audioscrobbler.com/1.0/artist/metallica/similar.xml

Deze webservice geeft een XML bestand terug, waaruit de nodige informatie kan gefilterd worden. Informatie van een muziekgroep zit ingebed binnen de XML tag <artist>, die zelf ook weer informatievelden bevat zoals hieronder in een voorbeeld wordt weergegeven.

```
<artist>
  <name>Pearl Jam</name>
  <mbid>83b9cbe7-9857-49e2-ab8e-b57b01038103</mbid>
  <match>28.15</match>
    <url>http://www.last.fm/music/Pearl+Jam</url>
    <image_small>http://userserve-ak.last.fm/serve/50/369658.jpg</image_small>
    <image>http://userserve-ak.last.fm/serve/160/369658.jpg</image>
    <streamable>1</streamable>
</artist>
```

In het linkerframe maak je een tabel op met in de eerste kolom de naam van elke groep (tag <name>), en in de tweede kolom een kleine afbeelding (tag <image_small>). Zorg ervoor dat de muziekgroepen op naam gesorteerd worden. Als in het linkerframe op een naam of een afbeelding geklikt wordt, moet de webpagina van de gelinkte URL (tag <url>) in het rechterframe getoond worden.

Elke regel uit het bestand steden.txt bestaat uit drie velden, gescheiden door tabs. De velden bevatten respectievelijk de naam van een continent, een land in dat continent, en een stad in dat land. De regels in dit bestand zijn niet noodzakelijk uniek. Je mag ervan uitgaan dat namen van steden uniek zijn per land, maar dat verschillende landen wel steden kunnen hebben met dezelfde naam. Gevraagd wordt om een bash shell script stats.sh te schrijven, dat de volgende statistieken berekent voor het bestand steden.txt:

- aantal records in het bestand
- aantal verschillende continenten
- aantal verschillende landen
- aantal verschillende steden
- minimaal aantal records per continent
- maximaal aantal records per continent
- minimaal aantal landen per continent
- maximaal aantal landen per continent

De naam van het bestand waarop de statistieken worden berekend, moet als parameter worden meegegeven aan het shell script. Indien het shell script wordt aangeroepen als

> stats.sh steden.txt

dan moet het de volgende informatie wegschrijven naar standaard uitvoer:

aantal records: 19813
aantal continenten: xxxxx
aantal landen: xxxxx
min records/continent: xxxxx
max records/continent: xxxxx
min landen/continent: xxxxx
max landen/continent: xxxxx

Op de plaats van de xxxxx komen natuurlijk getallen te staan, overeenkomstig de gevraagde statistieken.

EXAMEN: Computergebruik

Prof. Dr. Peter Dawyndt 1^e Bachelor Informatica groep 2 woensdag 23-01-2008, 14:00h academiejaar 2007-2008 eerste zittijd

Opgave 1

Het bestand dna.txt bevat regels die telkens uit twee velden bestaan, gescheiden door een spatie. In het eerste veld staan woorden die geen hoofdletters bevatten, en in het tweede veld staan DNA sequenties van 100 basen. Een DNA sequentie wordt voorgesteld door een tekenreeks met lettertekens uit het alfabet $\{A, G, C, T\}$, waarbij elk letterteken een base genoemd wordt.

- 1. Bepaal reguliere expressies voor elk van de onderstaande verzamelingen, waarbij \mathcal{D} de verzameling van alle DNA sequenties voorstelt. Probeer deze reguliere expressies zo kort mogelijk te houden.
 - (a) $\alpha = \{d \in \mathcal{D} \mid d \text{ bevat triplet van basen dat minstens drie keer na elkaar herhaald wordt}\}$ voorbeeld: ... AGCAGCAGC...
 - (b) $\beta = \{d \in \mathcal{D} \mid \text{ aantal opeenvolgende basen C of T in } d \text{ is altijd even}\}$
 - (c) $\gamma = \{d \in \mathcal{D} \mid \text{gedegenereerde DNA sequentie AGKYANBTD matcht juist één keer in } d\}$ uitleg: Een positie binnen een DNA sequentie die meerdere mogelijke alternatieve waarden kan hebben, wordt voorgesteld door een gedegenereerd basesymbool. Hieronder staat een lijst van alle gedegenereerde basesymboolen die internationaal werden vastgelegd.

base	betekenis		base	betekenis
W	A of T	_	В	G of T of C
S	G of C		D	$G ext{ of } A ext{ of } T$
M	A of C		H	A of C of T
K	$G \ \mathrm{of} \ T$		V	G of C of A
R	G of A		N	A of G of C of T
Υ	T of C			

Gebruik een commando uit de grep familie om enkel die regels van het bestand dna.txt te selecteren met een DNA sequentie die tot de opgegeven verzameling behoort. Vermeld in je antwoordbestand voor elke verzameling het gebruikte selectiecommando, en geef ook aan hoeveel regels je gevonden hebt.

- 2. Beschouw de verzamelingen α , β en γ zoals hierboven gedefinieerd. Gebruik nu deze verzamelingen om op de volgende manier een boodschap bestaande uit drie woorden te achterhalen:
 - (a) Het eerste woord staat op de unieke regel met de DNA sequentie uit verzameling $\alpha \cap \beta$.
 - (b) Het tweede woord staat op de unieke regel met de DNA sequentie uit verzameling $\alpha \cap \gamma$.
 - (c) Het derde woord staat op de unieke regel met de DNA sequentie uit verzameling $\beta \cap \gamma$.

Vermeld in je antwoordbestand de gevonden woorden, samen met de regelnummers in het bestand dna.txt waarop deze woorden gevonden werden. Geef voor elk woord ook het grep commando (of de commando-sequentie) die je gebruikt hebt om het woord te vinden.

Gegeven is een bestand munteenheden.txt, waarvan de regels de volgende vorm hebben:

```
<ISO-code> <land> <munt> <wisselkoers> <invoerdatum> <opmerking>
```

Elke regel bevat informatie over oude munteenheden die vervangen werden bij de introductie van de euro, waarbij komma's gebruikt worden als veldscheidingsteken. Sommige velden worden ook nog ingesloten tussen dubbele aanhalingstekens. Verder komen er geen aanhalingstekens en komma's meer voor binnen de velden. Het bestand bevat bovendien ook nog commentaarregels die beginnen met een hekje (#).

Gevraagd wordt om, gebruik makend van de teksteditor vi, een reeks substitutiecommando's te geven die achtereenvolgens de volgende opdrachten uitvoeren.

- 1. Zorg ervoor dat er telkens drie cijfers na het decimale scheidingsteken gebruikt worden in de wisselkoers. Zo moet 2.20371 vervangen worden door 2.203 (afkapping, geen afronding), en moet 1936.27 vervangen worden door 1936.270.
- 2. Gebruik drie commando's om elk veld in te sluiten tussen dubbele aanhalingstekens. Twee commando's om het begin en einde van een regel op te vangen, en één om de aanhalingstekens bij de veldscheidingen aan te passen. Maak daarna deze wijzigingen terug ongedaan (eventueel door het bestand opnieuw te openen).
- 3. Gebruik één enkel commando om elk veld in te sluiten tussen dubbele aanhalingstekens. Dit commando moet dus hetzelfde netto-effect hebben als de commando's uit het voorgaande puntje.
- 4. Reorganiseer het bestand zodat de records geordend zijn op munteenheid en daarna op land. Zorg ervoor dat de regels na herorganisatie dezelfde vorm behouden. Het kan zijn dat je hierbij meer dan één commando nodig hebt, maar de optimale oplossing gebruikt slechts één enkel commando.
- 5. Indien de munt is opgedeeld in verschillende eenheden, dan worden deze opgegeven in het veld munt gescheiden door een puntkomma. Zorg ervoor dat in de kolom munt enkel de eerste munteenheid behouden wordt indien er meerdere gegeven zijn. Voeg de andere munteenheden achteraan toe aan het veld opmerking, maar voor het dubbele aanhalingsteken. De beschrijving van de Belgische Frank wordt dan bijvoorbeeld:

```
"BEF", "België", "Frank", "40.339", "28/02/2002", "ook gebruikt in Luxemburg; Centimes"
```

Probeer zo weinig mogelijk commando's te geven en zo weinig mogelijk tekens te gebruiken in je commando's. De commentaarregels in munteenheden.txt mogen door je substituties niet gewijzigd worden. Alle wijzigingen moeten na elkaar uitgevoerd worden. Vermeld de gebruikte substitutiecommando's op je antwoordbestand.

Opgave 3

Gegeven zijn de volgende tekstfragmenten:

P	Populaire tags op Last.fm (http://www.last.fm)	
rock	8102 keer toegekend aan "Red Hot Chili Peppers"	
rock	5428 keer toegekend aan "Foo Fighters"	
non	2908 keer toegekend aan "Madonna"	
pop	971 keer toegekend aan "The Cardigans"	

2. **Definitie 1 (Kettingregel)** De kettingregel is een formule voor het bepalen van de afgeleide van een samengestelde functie. De meeste functies zijn samengesteld uit een aantal elementaire functies, waarvan de afgeleiden bekend zijn. Als een functie f te schrijven is als f(x) = g(h(x)), en de afgeleiden van de funties g en h zijn bekend, dan is

$$f'(x) = g'(h(x)) \cdot h'(x),$$

of eleganter in een meer gebruikte notatie:

$$\frac{df}{dx} = \frac{df}{dh}\frac{dh}{dx}$$

Definitie 2 (Meerdimensionale kettingregel) Stel dat f, g en h vectorwaardige functies zijn in meer dan één veranderlijke, bijvoorbeeld

$$h: D \subset \mathbb{R}^m \to E \subset \mathbb{R}^n, \ g: E \to \mathbb{R}^p, \ f = g \circ h: D \to \mathbb{R}^p$$

De meerdimensionale kettingregel zegt dat in dat geval f nog steeds differentieerbaar is in x, en dat zijn afgeleide de samengestelde lineaire afbeelding is van de afgeleiden van h en g:

$$f'(x) = g'(h(x)) \circ h'(x)$$

Als we de betrokken lineaire afbeeldingen schrijven als rechthoekige matrices (bestaande uit alle mogelijke partiële afgeleiden), dan is de matrix van f'(x) gelijk aan het product van de matrices van g'(h(x)) en h'(x):

$$\frac{\partial f_i}{\partial x_k} = \sum_{j=1}^n \frac{\partial g_i}{\partial x_j} \frac{\partial h_j}{\partial x_k} \qquad (i = 1, \dots, p; \ k = 1, \dots, m)$$

Hint: Om overtollig typwerk te vermijden, kan je voor bovenstaand kadertje enkele tekstfragmenten kopiëren uit het bestand kettingregel.txt.

3. Het bewijs voor Def. 1 gaat als volgt:

$$(g \circ h)'(x) = \lim_{x_0 \to x} \frac{(g \circ h)(x) - (g \circ h)(x_0)}{x - x_0}$$

$$= \lim_{x_0 \to x} \left[\frac{g(h(x)) - g(h(x_0))}{h(x) - h(x_0)} \cdot \frac{h(x) - h(x_0)}{x - x_0} \right]$$

$$= \dots$$

$$= g'(h(x)) \cdot h'(x)$$

Gevraagd wordt om LaTeX-code te genereren die precies hetzelfde resultaat oplevert als de tekstfragmenten binnen de bovenstaande kaders. Zorg ervoor dat formules en eigen omgevingen automatisch genummerd worden, en gebruik waar mogelijk verwijzingen naar deze nummeringen.

Opgave 4

Gevraagd wordt om een bash shell script albums te schrijven, waarmee de gebruiker kan navigeren in een lijst van albums van een opgegeven muziekgroep. Deze muziekgroep moet als parameter aan het shell script doorgegeven worden. De lijst van albums dient te worden opgemaakt in XHTML formaat. De weergave moet gebruik maken van twee verticale frames, waarbij de lijst van albums in het linkerframe wordt weergegeven. Zo moet het commando

> albums "pearl jam"

een reeks van bestanden genereren, die als volgt in een browser worden weergegeven:



Bovendien moeten alle webpagina's die het script genereert voldoen aan de XHTML 1.0 standaard. Om een lijst van albums van een muziekgroep te genereren, maak je gebruik van de webservice

```
http://ws.audioscrobbler.com/1.0/artist/<groep>/topalbums.xml
```

Binnen deze template-URL vul je op de plaats van <groep> de naam van een artiest of muziekgroep in. Let erop dat de naam van de artiest of muziekgroep uit meerdere woorden kan bestaan. Voor het bovenstaande voorbeeld wordt dit

```
http://ws.audioscrobbler.com/1.0/artist/pearl jam/topalbums.xml
```

Deze webservice geeft een XML bestand terug, waaruit de nodige informatie kan gefilterd worden. Informatie van een album zit ingebed binnen de XML tag <album>, die zelf ook weer informatievelden bevat zoals hieronder in een voorbeeld wordt weergegeven.

In het linkerframe maak je een tabel op met in de eerste kolom de naam van elk album (tag <name>), en in de tweede kolom een afbeelding (tag <medium>). Zorg ervoor dat de albums op naam gesorteerd worden, en dat de afbeeldingen allemaal dezelfde grootte hebben. Als in het linkerframe op een naam of een afbeelding geklikt wordt, moet de webpagina van de gelinkte URL (tag <url>) in het rechterframe getoond worden.

Het bestand hits.txt bevat een dump van het logbestand van een webserver. Elke regel bestaat uit vier velden, gescheiden door tabs. De velden bevatten respectievelijk het tijdstip waarop een aanvraag binnenkwam op de webserver, het IP adres van de gebruiker, het land waar het IP adres geregistreerd is, en de stad waar het IP adres geregistreerd is. Het spreekt vanzelf dat er verschillende aanvragen kunnen binnengekomen zijn vanaf een zelfde IP adres. Je mag ervan uitgaan dat namen van steden uniek zijn per land, maar dat verschillende landen wel steden kunnen hebben met dezelfde naam. Gevraagd wordt om een bash shell script stats.sh te schrijven, dat de volgende statistieken berekent voor het bestand hits.txt:

- totaal aantal hits
- aantal verschillende gebruikers (IP adressen)
- aantal verschillende landen
- aantal verschillende steden
- minimaal aantal hits per land
- maximaal aantal hits per land
- minimaal aantal gebruikers per land
- maximaal aantal gebruikers per land

De naam van het bestand waarop de statistieken worden berekend, moet als parameter worden meegegeven aan het shell script. Indien het shell script wordt aangeroepen als

```
> stats.sh hits.txt
```

dan moet het de volgende informatie wegschrijven naar standaard uitvoer:

aantal hits: 48020
aantal gebruikers: xxxxx
aantal landen: xxxxx
aantal steden: xxxxx
min hits/land: xxxxx
max hits/land: xxxxx
min gebruikers/land: xxxxx
max gebruikers/land: xxxxx

Op de plaats van de xxxxx komen natuurlijk getallen te staan, overeenkomstig de gevraagde statistieken.